

# Machine Learning Preprocessing

## Summary (Viva Ready)

| No | Preprocessing Family | সহজ ভাষায় কী?                                              | কেন দরকার?                        | Example                                      |
|----|----------------------|-------------------------------------------------------------|-----------------------------------|----------------------------------------------|
| 1  | <b>Missing Data</b>  | Dataset-এর যেই জায়গায় value নেই, সেটা handle করা          | Model missing value বুঝতে পারে না | Age: 20, 25, NaN → NaN fill/remove করা       |
|    | Methods              | Imputation, Deletion, MICE                                  |                                   |                                              |
|    | <b>Imputation</b>    | Missing value অনুমান করে বসানো                              | Data loss কম হয়                  | Salary missing → average salary বসানো        |
|    | <b>Deletion</b>      | Missing row/column remove করা                               | যদি missing অনেক কম হয়           | 1000 row-এর মধ্যে 5টা missing row delete     |
|    | <b>MICE</b>          | অন্য feature-এর relationship দেখে missing value predict করা | Complex dataset-এর জন্য           | Age + Experience দেখে missing salary predict |

---

| No | Preprocessing Family | সহজ ভাষায় কী?                   | কেন দরকার?                                         | Example                                            |
|----|----------------------|----------------------------------|----------------------------------------------------|----------------------------------------------------|
| 2  | <b>Data Cleaning</b> | Dataset-এর ভুল data পরিষ্কার করা | Data quality improve করার জন্য                     | Duplicate, wrong format, inconsistent value remove |
|    | <b>Duplicate</b>     | একই data বারবার থাকলে remove     | একই data model-কে বেশি গুরুত্ব দেওয়া থেকে বাঁচায় | Same network record 2 বার থাকলে 1টা রাখা           |
|    | <b>Noise</b>         | ভুল/অপ্রয়োজনীয় data            | Model ভুল pattern শিখতে পারে                       | Age = 500 (ভুল value)                              |
|    | <b>Inconsistency</b> | একই data বিভিন্ন format-এ থাকা   | Data uniform করা                                   | Dhaka, DHAKA, dhaka → Dhaka                        |

---

| N<br>o | Preprocessing<br>Family     | সহজ ভাষায় কী?                             | কেন দরকার?                                     | Example                       |
|--------|-----------------------------|--------------------------------------------|------------------------------------------------|-------------------------------|
| 3      | <b>Outlier</b>              | অস্বাভাবিক data খুঁজে<br>বের করা           | Extreme value<br>model-কে confuse<br>করতে পারে | Salary:<br>30k,40k,50k,500000 |
|        | <b>IQR</b>                  | Data range দেখে<br>unusual value<br>detect | Simple statistical<br>method                   | 500000 detect করা             |
|        | <b>Z-score</b>              | Mean থেকে কত দূরে<br>আছে দেখা              | Extreme value detect                           | $Z > 3$ হলে outlier           |
|        | <b>Isolation<br/>Forest</b> | ML দিয়ে abnormal<br>sample খোঁজা          | Large dataset-এর জন্য                          | Network attack<br>detection   |

| N<br>o | Preprocessing<br>Family        | সহজ ভাষায় কী?                       | কেন দরকার?                  | Example                                     |
|--------|--------------------------------|--------------------------------------|-----------------------------|---------------------------------------------|
| 4      | <b>Sampling</b>                | বড় dataset থেকে<br>কিছু data নেওয়া | Training দ্রুত<br>করার জন্য | 10 লাখ data থেকে 1 লাখ<br>নেওয়া            |
|        | <b>Under<br/>Sampling</b>      | বেশি class কমানো                     | Class balance<br>করা        | Normal 9000 $\rightarrow$ 1000              |
|        | <b>Over Sampling</b>           | কম class বাড়ানো                     | Minority class<br>শেখানো    | Attack 1000 $\rightarrow$ 9000              |
|        | <b>Stratified<br/>Sampling</b> | Class ratio একই<br>রাখা              | Fair train/test<br>split    | Train এবং test-এ<br>Normal/Attack ratio একই |

| N<br>o | Preprocessing<br>Family | সহজ ভাষায় কী?                        | কেন দরকার?                          | Example                      |
|--------|-------------------------|---------------------------------------|-------------------------------------|------------------------------|
| 5      | <b>Imbalance</b>        | Class-এর data সংখ্যা<br>সমান না হওয়া | Model যেন শুধু বড়<br>class না শেখে | Normal=9000,<br>Attack=1000  |
|        | <b>SMOTE</b>            | নতুন minority sample<br>তৈরি করে      | Minority বাড়ানো                    | নতুন Attack sample<br>তৈরি   |
|        | <b>ADASYN</b>           | কঠিন minority sample<br>বেশি তৈরি করে | Difficult case<br>শেখানো            | Hard attack বেশি<br>generate |

|    | Class Weight         | কম class-কে বেশি importance দেওয়া    | Data না বদলে model balance করা      | Attack ভুল করলে বেশি penalty |
|----|----------------------|---------------------------------------|-------------------------------------|------------------------------|
| No | Preprocessing Family | সহজ ভাষায় কী?                        | কেন দরকার?                          | Example                      |
| 6  | Transformation       | Data-এর distribution পরিবর্তন করা     | Skewed data ঠিক করার জন্য           | 100,200,10000                |
|    | Log Transformation   | বড় value ছোট করা                     | Extreme value effect কমানো          | 10000 → smaller scale        |
|    | Box-Cox              | Data normal করার চেষ্টা               | Positive data-এর জন্য               | Income data                  |
|    | Yeo-Johnson          | Positive + negative দুইটাই handle করে | Flexible transformation             | Temperature data             |
| No | Preprocessing Family | সহজ ভাষায় কী?                        | কেন দরকার?                          | Example                      |
| 7  | Scaling              | Feature-এর range একই করা              | বড় value যেন বেশি influence না করে | Age=20, Salary=50000         |
|    | Standard Scaling     | Mean=0, SD=1                          | Logistic Regression/SVM-এর জন্য     | Value normalize              |
|    | Min-Max              | 0 থেকে 1 range                        | Fixed range দরকার হলে               | Pixel values                 |
|    | Robust Scaling       | Median/IQR ব্যবহার করে                | Outlier থাকলে ভালো                  | Salary dataset               |
| No | Preprocessing Family | সহজ ভাষায় কী?                        | কেন দরকার?                          | Example                      |
| 8  | Encoding             | Text data-কে number করা               | ML model text বুঝে না               | TCP → number                 |
|    | One-Hot Encoding     | প্রতিটা category-এর আলাদা column      | False order তৈরি করে না             | TCP, UDP, HTTP               |
|    | Ordinal Encoding     | Order থাকলে number দেওয়া             | Ranking data-এর জন্য                | Low=1 Medium=2 High=3        |

|    | Target Encoding         | Target অনুযায়ী category value                 | High category data                             | City অনুযায়ী average |
|----|-------------------------|------------------------------------------------|------------------------------------------------|-----------------------|
| No | Preprocessing Family    | সহজ ভাষায় কী?                                 | Example                                        |                       |
| 9  | Feature Engineering     | নতুন useful feature তৈরি করা                   | Existing data থেকে extra information বের করা   |                       |
|    | Aggregation             | অনেক feature combine করা                       | Source bytes + Destination bytes = Total bytes |                       |
|    | Interaction             | Feature-এর relationship বের করা                | Bytes/Packet                                   |                       |
|    | Temporal Feature        | Time থেকে feature বানানো                       | Timestamp → Night/Day                          |                       |
| No | Preprocessing Family    | সহজ ভাষায় কী?                                 | Example                                        |                       |
| 10 | Feature Selection       | Important feature রাখা, unnecessary বাদ দেওয়া | 50 feature → best 10 feature                   |                       |
|    | MI                      | Feature কত useful measure করা                  | Packet count important কিনা                    |                       |
|    | RFE                     | ধাপে ধাপে feature remove                       | 20 → 10 feature                                |                       |
|    | LASSO                   | কম important feature-এর weight zero            | Feature remove                                 |                       |
| No | Preprocessing Family    | সহজ ভাষায় কী?                                 | Example                                        |                       |
| 11 | Simulation/Augmentation | নতুন data তৈরি করা                             | Data কম হলে বাড়ানো                            |                       |
|    | Monte Carlo             | Random simulation                              | Traffic simulation                             |                       |
|    | GAN                     | Existing data দেখে নতুন realistic data তৈরি    | New leaf image                                 |                       |
|    | VAE                     | Data pattern শিখে generate                     | Synthetic sample                               |                       |

Diffusion

Noise থেকে data তৈরি

AI image  
generation

| No | Preprocessing               | সহজ ভাষায় কী?                    | Example                     |
|----|-----------------------------|-----------------------------------|-----------------------------|
|    | Family                      |                                   |                             |
| 12 | <b>Statistical Analysis</b> | Data-এর relationship analysis করা | Feature important কিনা দেখা |
|    | t-test                      | দুই group compare                 | Normal vs Attack            |
|    | ANOVA                       | তিন বা বেশি group compare         | DoS vs DDoS vs Scan         |
|    | Chi-square                  | Categorical relationship          | Protocol vs Attack          |
|    | Mann-Whitney                | Non-normal দুই group compare      | Traffic comparison          |
|    | p-value                     | Difference significant কিনা       | $p < 0.05$                  |
|    | Effect Size                 | Difference কত বড়                 | Practical importance        |

Missing → value নেই

Cleaning → ভুল data ঠিক

Outlier → অস্বাভাবিক data

Sampling → data কমানো

Imbalance → class balance

Transformation → data shape ঠিক

Scaling → range equal

Encoding → text to number

Feature Engineering → নতুন feature

Feature Selection → ভালো feature রাখা

Augmentation → data বাড়ানো

Statistics → relationship খোঁজা